

**VIVIAN CABANZO FERNÁNDEZ
LAURA DANIELA DIAZ TORRES
CRISTIAN FELIPE MUÑOZ GUERRERO
ZENNETH OLIVERO TAPIA**

Problem Set 3 – Making Money with ML?

**BIG DATA Y MACHINE LEARNING PARA
ECONOMIA APLICADA**

2025-02

data_equipo_08

Limpieza de datos, construcción y transformación
de variables, definición de bases de datos finales.

Best model overview – Random Forest CV espacial

Elemento	Descripción
Tipo de modelo	Random Forest con validación cruzada espacial (ensamble por folds)
Objetivo / Métrica	Minimizar MAE (validación 5-fold)
Hiperparámetros	num.trees = 1000; mtry $\approx \sqrt{p}$; min.node.size = 10; sample.fraction = 0.80; splitrule = variance; seed = 2025
Esquema de validación	Regular 5-fold: MAE = 120,886,984; Espacial 5-fold: MAE = 131,308,700
Estrategia de predicción	Promedio de las K predicciones por fold espacial (ensamble por folds)
Top variables	surface_total, bedrooms, estrato, dist_centros_comerciales, has_parqueadero_garaje, localidad
Kaggle (public LB)	209,389,203

Usando el CV espacial se generalizaron mejor las zonas no vistas. El ensamble por folds reduce varianza y el bosque capta no linealidades e interacciones entre tamaño, ubicación, distancias y amenidades, entregando predicciones estables sin sobreajuste.


BASES DE DATOS INICIALES

Las bases de datos iniciales de entrenamiento y de prueba, fueron construidas a partir de los datos recopilados del portal web <https://www.properati.com.co>

- train.csv cuenta con 38.644 observaciones y 16 variables
- test.csv cuenta con 10.286 observaciones y 16 variables

VARIABLE	DESCRIPCIÓN	VARIABLE	DESCRIPCIÓN
Property_id	Identificador único asignado a cada propiedad, usado para diferenciar registros y evitar duplicados.	Bedrooms	Cantidad de habitaciones destinadas a dormitorio.
City	Ciudad en la que se ubica la propiedad según la publicación en el portal.	Bathrooms	Número total de baños disponibles en la propiedad.
Price:	Precio de venta ofertado para la propiedad, reportado directamente por el anunciante.	Property_type	Tipo de propiedad anunciada (casa o apartamento).
Month	Mes de publicación del anuncio en el portal.	Operation_type	Tipo de operación del anuncio (venta o arriendo).
Year	Año de publicación del anuncio.	Lat	Latitud geográfica de la propiedad.
Surface_total	Superficie total del inmueble en metros cuadrados (m2).	Lon	Longitud geográfica de la propiedad, utilizada para ubicar espacialmente el inmueble.
Surface_covered	Superficie construida o cubierta del inmueble en m2. Puede diferir de la superficie total.	Title	Titulo del anuncio publicado en el portal, usualmente con información breve y destacada.
Rooms	Número total de ambientes o espacios de la vivienda (sala, comedor, estudio).	Description	Descripción de texto del anuncio con detalles adicionales sobre características del inmueble.


DISTRIBUCIÓN ESPACIAL DE LAS BASES



Exploración espacial de las bases de datos, de acuerdo con las variables de Longitud y Latitud.

- Viviendas con información para el entrenamiento de modelos – Bogotá.
- Viviendas sobre las cuales se realizarán predicciones de precios de venta – Localidad de Chapinero.

Comparación de % de valores faltantes por variable
Train vs Test




Porcentaje de datos faltantes en las bases de entrenamiento y de prueba:

Variable	Train	Test
Surface total	79,68%	81,88%
Surface covered	77,84%	72,52%
Rooms	47,25%	44,25%
Bathrooms	26,06%	24,22%
Price	0%	100%

VALORES ATÍPICOS

Detección visual de outliers



La variable Surface_total a pesar de tener un porcentaje alto de faltantes, también presenta valores atípicos altos, con superficies superiores a los 2.000 m².


ADECUACIÓN DE LOS DATOS Y CONSTRUCCIÓN DE NUEVAS VARIABLES

PROCESO	DESCRIPCIÓN
Procesamiento de texto	<ul style="list-style-type: none"> - Normalización y unificación de texto - Diccionario de palabras con atributos clave (parqueadero, balcón, patio, etc.) - Tokenización de palabras para identificar su presencia y frecuencia - Creación de 19 variables dicotómicas adicionales
Análisis espacial y geográfico	<ul style="list-style-type: none"> - Información de OpenStreetMap – OSM de Colombia - Delimitación de la ciudad de Bogotá - Identificación de puntos de interés urbano (parques, colegios, centros comerciales, restaurantes y autopistas), calculo de la distancia de las viviendas a dichos puntos. - Creación de 7 variables adicionales
Inclusión del estrato socioeconómico	<ul style="list-style-type: none"> - Información del DANE: - i). Un archivo geoespacial LOTE.gpkg - ii). Una tabla estrato.csv - El proceso crea 1 variable que asocia a cada lote su estrato correspondiente.

ANÁLISIS GEOESPACIAL

Viviendas y Puntos de Interés

Fuentes: OpenStreetMap y GeoFabrik Colombia



Punto de interés Parques Colegios Restaurantes Autopistas Centros comerciales

TRATAMIENTO DE DATOS FALTANTES Y VALORES ATÍPICOS

PROCESO	DESCRIPCIÓN
Eliminación de observaciones	<ul style="list-style-type: none"> - 414 observaciones con descripción que indica que la propiedad no se encuentra en Bogotá a pesar de que su ciudad de registro indica que si. - 1.731 por el buffer o franja de 500 metros alrededor de Chapinero en la base de entrenamiento para evitar solapamiento y autocorrelación espacial. - 4.426 observaciones idénticas, análisis realizado por combinación de título, descripción, precio, latitud y longitud.
Imputación de Surface total y superficie construida	<ul style="list-style-type: none"> - Se identificaron los datos mayores a 1.500 m², se reemplazaron con NA para no perder la información de su registro. - Se asignó el valor de superficie construida cuando esta superaba a la superficie total reportada. - Si una de las dos superficies estaba disponible, se utilizó dicho valor para completar la variable faltante. - Los casos restantes se imputaron empleando la mediana de superficie, estimada no por los valores totales sino por tipo de propiedad y número de habitaciones.
Imputación de Baños	<ul style="list-style-type: none"> - Se implementó una regla de imputación basada en la cantidad de habitaciones y el tipo de propiedad, bajo el supuesto que toda vivienda debe contar con al menos un baño.
Imputación de Ambientes – romos	<ul style="list-style-type: none"> - De manera análoga, se imputó la cantidad mínima de ambientes en función del tipo de propiedad, garantizando la presencia de, por lo menos, un espacio correspondiente a sala-comedor.

BASES DE DATOS FINALES

En resumen: La información final se obtuvo mediante la unión y depuración de las distintas fuentes disponibles, incorporando transformaciones de variables, extracción automatizada de atributos a partir del texto, y la creación de variables relacionadas con características físicas, atributos geográficos y condiciones socioeconómicas.




CATEGORÍA	CANTIDAD	VARIABLES
Variables Iniciales	16	Identificación de la propiedad, ciudad, precio, mes, año, superficie total, superficie construida, ambientes, baños, habitaciones, tipo de propiedad, tipo de operación del anuncio, latitud, longitud, título y descripción.
Variables dicotómicas a partir de texto	19	Presencia de: parqueadero o garaje, seguridad, ascensor, gimnasio, piscina, BBQ, salón social, zona infantil, balcón, terraza, patio, jardín exterior, chimenea, cocina integral, depósito, estudio, remodelado, vista y pisos de vivienda.
Variables de distancia a puntos de interés	5	Distancias a parques, colegios, restaurantes, autopistas y centros comerciales.
Otras variables	3	Localidad, barrio y estrato
TOTAL	43	Variables en train_final.csv y test_final.csv

ESTADÍSTICAS DESCRIPTIVAS

Histogramas de variables numéricas de la base de entrenamiento



ESTADÍSTICAS DESCRIPTIVAS



RELEVANCIA DE LA INFORMACIÓN PARA LA PREDICCIÓN DE PRECIOS DE VIVIENDA EN CHAPINERO

Las bases de datos consolidadas, resultado de los procesos previamente descritos, son pertinentes para la predicción de precios de venta en la localidad de Chapinero, debido a que integran información que captura de manera adecuada los factores que explican la variación del valor de las viviendas en Bogotá.